Epigenesis: промяна на ДНК и симулация на последствията за невронното развитие

Деян Тодоров

Технически доклад, чернова 3 · 13 ноември 2026 г. (Epigenesis 1.7.0) · English version: epigenesis-technical-paper.pdf
Код: `https://github.com/dttdrv/epigenesis` (Apache-2.0)

Резюме

Epigenesis е софтуер, с който се променя участък от ДНК и се наблюдава какво следва в симулирана развиваща се система. Той чете ДНК източник при изрично тълкуване на значението на ДНК, компилира го в адресируем по съдържание модул за развитие (Development Module) и повтаря всяка компилация с отделен валидатор. Докладът описва компилатора, архитектурата за проверка и двата свързани невронни работни процеса до версия 1.7.0. Първо, механистичната верига свързва ДНК сайт — а от 1.7 и човешки енхансери с произволна дължина чрез симетрична по вериги Болцманова сума на състоянията за GLI2/GLI3 на Hallikas, 532 мотива на гръбначни от JASPAR 2024 или потребителски матрици — към произволни регулаторни диференциални уравнения за N гена, компилирани в запечатани модули `brainc` v2/v3. В 9-базов сайт за GLI на *Nkx2.2* замяната на GACCACCCA с GAACACCCA премества симулирания Nkx2.2 от 0,940 до 0,0085, докато пасивната заетост на промотора се променя едва от 0,940 на 0,928, а връщането на базата възстановява референтната траектория точно. Сканирането на пълен човешки енхансер от 171 бази (`chr15:90936956–90937127`) разкрива 7 скрити бифуркации сред 513 замени (33 в пет локуса от GSE188264), епистатични спасявания чрез втора мутация при субоптимални енхансери и 74 скрити прехода в многофакторна трилинийна верига. Второ, два процесорни предсказвателя от последователност оценяват ефектите на варианти в репортерни анализи: Huber-линеен модел върху данните от SK-N-SH (вътрешна грешка с 3,02% под 5-мери, но външна корелация между изследванията 0,049 и грешка с 9,52% над нулев ефект) и ортогонален мотивно-времеви ридж предсказвател за неврална индукция 0–72 ч в H1 (`motif_temporal`, ретроспективна MSE върху задържани семейства 0,252079 срещу 0,285185 за 5-мери в 118 семейства). Epigenesis Studio (v0.2.0) и обединен команден ред изпълняват тези процеси локално на английски и български и изнасят канонични SHA-256 удостоверения за независимо възпроизвеждане.

Ключови думи: ДНК компилатор, регулаторни варианти, Болцманова сума за афинитет, скрити бифуркации, невронно развитие, възпроизводимост, предсказване на ефекта на варианти.

1 Увод

Изследовател, който променя регулаторен ДНК сайт, иска да знае какво прави промяната с една развиваща се система, по възможност преди да избере лабораторен експеримент. За отговора е нужна верига от стъпки: кои бази се променят, как промяната влияе на свързването, как това влияние влиза в динамичен модел и как моделът реагира във времето. На практика веригата живее в скриптове, които не записват допусканията си. Затова резултатът не може да се проследи до байтовете на източника и друг човек не може да го повтори.

Epigenesis третира ДНК записа като изходен код на програма. Профилът на източника определя граматиката и идентичността на записа. Потребителят задава тълкуване, което казва какво се приема, че означава ДНК. Компилаторът свежда двете до типизиран модул за развитие, независим валидатор повтаря извеждането, а изпълнимите модели четат запечатания модул. Компилацията се приема само ако тази втора реализация я възпроизведе.

Докладът следва реда, в който изследователят среща софтуера. Раздел 3 описва компилатора, валидатора, обединения команден ред и изпълнимите експерименти. Раздел 4 представя механистичната верига: първо работния пример с 9-базов сайт за GLI, а после обобщението във версия 1.7

към пълни енхансери, многомотивно Болцманово свързване, произволни вериги от N гена, епистатични спасявания с втора промяна и връзка към структурна тъканна симулация. Раздел 5 описва предсказвателите по последователност — контролната точка на Siraj с Huber-линеен модел и нейните граници на пренос, както и мотивно-времевия модел на Kreimer за неврална индукция 0–72 ч. Раздел 6 описва Epigenesis Studio, което изпълнява всички процеси, а раздел 7 посочва границите.

Сред разработките, разгледани в раздел 2, няма такава, която да компилира съществуваща ДНК при изрично тълкуване и с независимо повторно изпълнение. Това е ограничено сравнение; не сме правили пряк тест срещу други инструменти. Компилаторът не извежда биология от последователността, защото тълкуването е входна величина. Симулациите важат при заявените си допускания и не предсказват изхода при ембриони.

2 Сходни разработки

Компилатори за ДНК. Няколко системи компилират описание на проект до ДНК или генетични вериги: атрибутни граматики (Cai et al. 2009), пространствен език, компилиран до регулаторни мрежи (Beal et al. 2011), езиците Eugene и Genotype Specification (Bilitchenko et al. 2011; Wilson et al. 2016) и Cello (Nielsen et al. 2016). Epigenesis работи в обратната посока: взема съществуваща ДНК и изрично тълкуване и ги свежда до вход за модел.

Симулирано развитие. CX3D израства неврони и мрежи от локални правила (Zubler and Douglas 2009). Управлява го език за инструкции (Zubler et al. 2011), приложен и към развитието на кората (Zubler et al. 2013). Два експеримента тук (`neural-construction` и структурното свързване в `neural-circuit`) използват CX3D.

Възпроизводими модели. Архивите COMBINE пакетират модела заедно с данните и метаданните му (Bergmann et al. 2014). Epigenesis е по-тесен. Той определя какво трябва да записва извеждането от ДНК.

Биологични модели в експериментите. Отчитането на градиента на Sonic Hedgehog в невралната тръба е добре количествено описан модел на решенията за клетъчна съдба (Balaskas et al. 2012; Cohen et al. 2014; Herrera-Delgado et al. 2020). Данни за енхансера дават Peterson et al. (2012), а за афинитета на свързване Hallikas et al. (2006).

Предсказване на ефекта на варианти. Раздел 5 и приложение Б използват данни от репортерни анализи (Melnikov et al. 2012; Tewhey et al. 2016; Kircher et al. 2019; Kreimer et al. 2022) и сравнения с модели от последователност към функция (Zhou and Troyanskaya 2015; Kelley et al. 2016, 2018; Avsec et al. 2021; Chen et al. 2022). Доставените предсказватели съчетават регуляризирана регресия (на Хюбер Huber 1964 или ортогонална времева ридж регресия) с мотивни оценки от JASPAR 2024 (Rauluseviciute et al. 2024). И двата метода са утвърдени. Нашият принос е реализираният, проверен и възпроизводим работен процес около тях.

3 Софтуерът

3.1 Компилатор и договори

Компилаторът превръща ДНК източник в модул за развитие на четири етапа:

$$\text{ДНК източник} \rightarrow \text{типизиран пакет на източника} \rightarrow \text{изрично тълкуване} \rightarrow \text{модул за развитие}$$

Вградените профили четат суров IUPAC, FASTA, поточен референтен FASTA, GenBank и GFF3. Други граматики влизат през външен интерфейс от версия 2. Той е изпълним файл, закрепен по хеш, със самостоятелен изпълним валидатор. Потребителят задава тълкуването (манифест, заявка, отговор), политиката за свеждане и целевия договор. Компилаторът проверява типовете, координатите, препратките и ограниченията по ресурси. Версия 1.7 добавя договорите `brainc` v3

редом с v1/v2 за двойки във вериги с множество транскрипционни фактори и мотивно-времеви предсказания при произволна дължина, като запазва всяка схема и хеш идентичност на v1/v2 и предоставя обединен команден ред със стандартната библиотека (`epigenesis`, `epigenesis_cli.py`).

Всеки артефакт е затворен JSON обект. На всяко ниво компилаторът отхвърля непознати или липсващи членове, дублирани ключове, некрайни числа, цели числа извън $\pm(2^{53}-1)$ и грешни типове. Идентичностите са SHA-256 хешове на каноничното кодиране по RFC 8785 (Rundgren et al. 2020; NIST 2015). Идентичностите на последователностите следват схемата refget на GA4GH. `SPEC.md` описва договорите. `docs/reference/STANDARDS.md` свързва всеки договор със съответната спецификация.

3.2 Независима проверка

Валидатор, изолиран от производителя на артефакта, чете наново оригиналния източник, изпълнява външните валидатори върху нови моментни копия и повтаря свеждането и свързването. Той не внася кода на производителя. Пакетът за издание 1.7 изпълнява 535 модулни и интеграционни теста (четири се пропускат при липса на незадължителните Java/външни инструменти), 32 теста на Studio и цялостни проверки на изданието (`tests/verify.py`), обхващащи минималния пример, универсалния превод, граничните условия, атаки срещу договорите, безопасност на пътищата, компилация на реална ДНК, `neural-circuit`, `neural-regulation-motif`, `neural-construction` и инсталиране от wheel и архив с изходен код. Минималният пример възпроизвежда четири фиксирани хеша: на описанието на източника, на модула за развитие, на пакета за развитие и на отчета от валидацията.

3.3 Изпълними експерименти

Всеки експеримент посочва входните данни, допусканията, контролите и твърдението, което подкрепя (таблица 1). Оформянето на невралната тръба и невралната верига образуват механистичната верига от раздел 4.

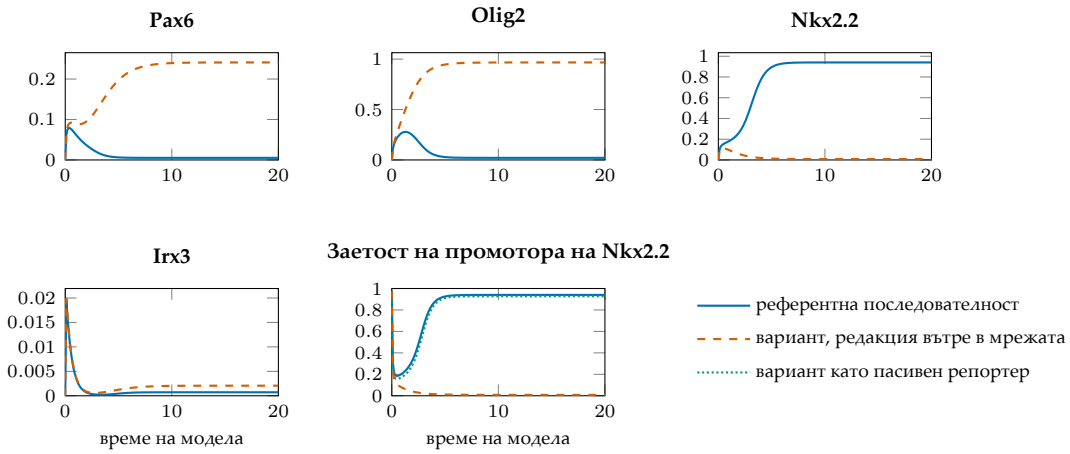
Два по-ранни експеримента завършиха с отрицателен резултат и остават в хранилището (приложение Б). Експериментите показват, че веригата от ДНК през изрично тълкуване до механистичен модел може да се изпълни и да се провери. Те не показват, че тълкуванията са верни.

4 Работен пример: промяна на сайт за GLI

4.1 Въпросът и веригата

Въпросът е как зададена промяна в ДНК изменя динамиката на модел на невронно развитие. Примерът е експериментът `examples/neural-patterning`. Всяка стъпка по-долу е отделна част от данните или кода в хранилището и всяко допускане е заявено.

1. **Сайт.** Peterson et al. (2012) тестват замяна в сайт за свързване на GLI в енхансера на *Nkx2.2* на -2 kb. В ориентацията на веригата от таблицата за свързване деветбазовото ядро се променя от GACCACCCA на GAACACCCA: замяна на C с A в позиция 3. Хранилището съдържа само тези ядра; пълният енхансер не е включен.
2. **Свързване.** Hallikas et al. (2006) измерват свързването на GLI2 и GLI3 с всяка замяна на една база в консенсусния сайт. Съотношението q между мутантния и референтния сайт за тази замяна е 0,0424 за GLI2 (основният избор) и 0,0353 за GLI3 (проверка на чувствителността). Компилаторът превръща избрания сайт в модул за развитие, който съхранява само избраните нуклеотиди (тензорите `count` и `nucleotides`). Симулацията чете тези бази обратно от валидирания модул и извежда q от таблицата на свързването.
3. **Пренос.** По заявено допускане q умножава афинитета към GLI на промотора на *Nkx2.2* в модела с четири гена на Herrera-Delgado et al. (2020), чийто механизъм на конкурентно свързване следва Cohen et al. (2014). Нека S е делът на GLI в активаторна форма, w е базовото тегло, K е



Фигура 1. Траекториите зад таблица 2. В четирите панела за гени пунктираната линия е вариантът като редакция вътре в мрежата. В панела за заетостта точковата линия е вариантът като пасивен репортер, който остава близо до референтната (в края 0,928 срещу 0,940). Режимът на репортер оставя и четирите гена върху референтната траектория.

коефициентът за GLI, c е коефициентът на активиране и D е факторът на кръстосана репресия. Промоторът е активен с вероятност P, тоест неговата заетост:

$$P = \frac{w(1+K)(1+qcKS)}{w(1+K)(1+qcKS) + (1+qK)D}, \qquad \frac{dX}{dt} = 2P - 2X,$$

където X е концентрацията на генния продукт в единици на модела. За референтния сайт $q = 1$ и факторът $1 + K$ се съкращава, което възстановява публикуваните уравнения. При фиксирано ендогенно състояние по-слабият сайт намалява заетостта при сигнали над $S = 1/c = 0{,}1$ и я увеличава под тази стойност.

4. ***Динамика.*** Четирите гена Pax6, Olig2, Nkx2.2 и Irx3 се интегрират с адаптивни стъпки по метода на Рунге–Кута от четвърти ред при историята на сигнала и началното състояние, които задава потребителят. Концентрациите и времето са в единици на модела.

4.2 Референтна последователност, вариант и връщане

Изпълнихме референтния сайт и варианта при един протокол: дял на GLI активатора 0,2 за 20 единици на модела, като и четирите гена започват от нула. Вариантът се изпълнява по два начина. Като редакция вътре в мрежата (ендогенен режим) променената стойност на афинитета се връща обратно във всичките четири гена. Като пасивен репортер (режим на репортер) промоторът отчита заетост върху непроменената референтна мрежа. Третото изпълнение връща базата и повтаря референтното.

С по-слабия сайт Nkx2.2 вътре в мрежата завършва с 0,0085, докато референтната последователност завършва с 0,940. Останалите гени следват. В този модел Nkx2.2 потиска Pax6, Olig2 и Irx3, затова по-малкото Nkx2.2 ги освобождава: Olig2 расте от 0,021 до 0,967, а Pax6 от 0,0052 до 0,241. При отчитане през пасивен репортер същата замяна променя заетостта на промотора само от 0,940 на 0,928 и оставя и четирите гена върху референтната траектория. Репортерен анализ би показал малка промяна при редакция, чийто ефект вътре в мрежата с обратна връзка е голям. При GLI3 вместо GLI2 вариантът завършва с Nkx2.2 0,0081.

Връщането на базата дава траектория, идентична с референтната във всичките 201 момента на изхода и за четирите гена (най-голяма абсолютна разлика 0), а върнатият сайт се компилира до същия модул за развитие като референтния. Програмата на примера добавя дванайсет проверки на механизма и всички минават при демонстрационното изпълнение. Спасяването чрез медиатор запазва ДНК на варианта и налага референтния множител. Фенокопието запазва референтната ДНК и налага множителя на варианта. Контролът за история на сигнала показва, че

еднакви крайни сигнали могат да оставят различни състояния на Nkx2.2. Други проверки обхващат обръщането на знака на ефекта от свързването при различни сигнали и сходимостта, когато интервалът на изхода се преполови (разлики под 10^{-4}).

4.3 Допускания и обхват

Резултатът зависи от шест заявени допускания, изброени в `examples/neural-patterning/data.json` и показвани при всяко изпълнение в Studio.

1. Публикуваното нормализирано съотношение от профила на свързване се пренася като относителен множител на афинитета. Първоначалният процес на нормализиране не е напълно възстановен.
2. Един и същ GLI профил мащабира афинитета на активатора и на репресора. GLI2 е основният избор, а GLI3 е анализ на чувствителността.
3. Деветбазовият сайт е отнесен към публикуван регулаторен контекст на *Nkx2.2*. Останалата последователност на енхансера, хроматинът и кофакторите са фиксирани и не се моделират.
4. Режимът на репортер отчита заетостта на промотора върху непроменена ендогенна траектория. Ендогенният режим е хипотетична редакция на генома с обратна връзка.
5. Сигналът е делът на GLI активатора в $[0, 1]$. Той не е калибрирана концентрация на Shh.
6. Времето и концентрацията са в единици на модела. Не се извежда флуоресцентна скала, праг на откриване, биологичен часовник или вероятност за ембрион.

При Peterson et al. (2012) репортерът на *Nkx2.2* е експресиран при 4 от 6 ембриона с референтния сайт и при 0 от 13 с варианта (E10.5). Моделът няма праг на откриване и модел на шума на ниво ембрион, затова тези броеве се показват до симулацията и не се оценяват като възпроизведено предсказание. Моделът с четири гена не включва Foxa2.

Поддържаният 9-базов вход е една замяна с измерено положително тегло на свързване в този сайт, протокол на сигнала до 10 фази и 100 единици на модела и по избор начално състояние. Версия 1.7 премахва това ограничение чрез `examples/neural-circuit`.

4.4 Обобщение към пълни енхансери и произволни вериги от N гена

За да се излезе от един 9-базов консенсусен сайт и една фиксирана схема с четири гена, `neural-circuit` свързва произволни регулаторни последователности директно с потребителски вериги от N диференциални уравнения (`CircuitSpec`, от 1 до 64 гена). За произволна матрица на свързване M на транскрипционен фактор — профилите GLI2/GLI3 на Hallikas, коя да е от 532-те матрици на гръбначни в JASPAR 2024 или потребителска матрица — сумата на състоянията (Болцманова статистическа сума) по всички плъзгащи се прозорци на двете вериги е

$$Z(S_{\mathrm{DNA}}, M) = \sum_{i=1}^{L-W+1} \frac{w_{+,i} + w_{-,i}}{2} + \varepsilon, \qquad q = \frac{Z(S_{\mathrm{var}}, M)}{Z(S_{\mathrm{ref}}, M)},$$

с псевдоброй по подразбиране $\varepsilon = 10^{-4}$ (при $\varepsilon = 0$ върху 9-базовия сайт GAACACCCA възпроизвежда измереното съотношение 0,0423555 с точност под 10^{-15}). Съотношенията се свързват към отделни гени като активатори (q) или репресори ($1/q$) при конкурентно или чисто активаторно заемане, а двойките алели се компилират с точно връщане на последователността в запечатани модули `brainc` v2 или v3, поддържащи замени (SNV), многонуклеотидни промени (MNV) и вмъквания/изтривания.

В реални човешки енхансери от 171 бази от GSE188264 (таблица 3) сканирането на всички $3L = 513$ единични замени разкрива *скрити бифуркации*: варианти, които променят пасивната заетост на промотора с под 0,02, но преминават праг на седловидно-възлова бифуркация в ендогенната обратна връзка и обръщат крайната клетъчна съдба. Върху `chr15:90936956-90937127` с GLI2 ($S = 0{,}20$) 7 замени са скрити бифуркации (включително `60:C>A`, $q = 0{,}042455$, пасивен репортер $-0{,}0124$, ендогенен Nkx2.2 $-0{,}9318$, усилване $75{,}2\times$ и пространствено свиване на домена

P3 от $x = 0{,}25$ на $0{,}125$). В пет подбрани енхансера от GSE188264 33 замени действат като скрити бифуркации, а субоптималните енхансери (`chr18:56475717–56475888` и `chr1:175099416–175099587`) допускат епистатични замени на втора позиция, които възстановяват дивия тип съдба без връщане на първичната мутация. Прилагането на същия механизъм към многофакторна трилинийна верига (`tri-lineage-switch`: активатор `MA0069.1` PAX6 върху `Excitatory`, съчетан с репресор `MA0463.3` BCL6 върху `Inhibitory`) дава 74 скрити прехода на `chr15` (напр. `24:T>C`, преместваща `Excitatory` към `Progenitor`, $\Delta = 0{,}8149$ срещу пасивно $0{,}0$). Установените състояния могат по избор да се сведат до 480-базовата рецепта за изграждане в CX3D за проверки на морфогенезата и LIF предаването. Всеки обобщен резултат остава условен спрямо допусканията за пренос на афинитета и некалибрираните единици (`biological_acceptance = False`).

5 Предсказвателят на редакции

Симулацията от раздел 4 следва една избрана промяна през механистичен модел. Предсказвателят разглежда много кандидат-редакции наведнъж. За всяка той оценява само по последователността с колко редакцията променя активността на репортера и в каква посока. Изследователят може да ползва оценките, за да подреди редакциите и да избере панел за измерване. Studio изпълнява предсказвателя в разделите Сканиране и Редакции (раздел 5.4).

5.1 Задача и данни

Задача. При дадени референтна и редактирана последователност да се оцени ефектът върху активността на репортера, алтернативен минус референтен ($\log_2$ на отношението), в 24-часовия анализ в SK-N-SH на Siraj et al. (2026). Допускат се замени, вмъквания и изтривания. Оценката подрежда редакциите в рамките на този анализ. Тя не е вероятност и не симулира развитие.

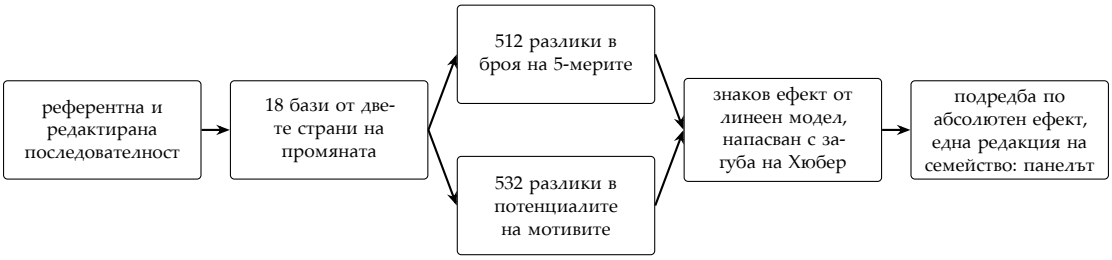
Скрининг и дялове. Скринингът на Siraj има 365 762 двойки конструкти, 336 475 от които с два алела по 200 бази, измерени с поне пет повторни трансфекции на библиотека. Редакциите са групирани в семейства, свързани компоненти от припокриващи се или идентични конструкти (включително обратно-комплементарни), така че сродни редакции никога не попадат от двете страни на разделянето. Крайният модел е напасван върху дяла за напасване (FIT), 66 604 редакции в 6794 семейства, и е сравняван върху вътрешния дял за настройка (TUNING), 16 986 редакции в 1759 семейства. Още един дял, RESERVE, не е оценяван и остава запечатан. Разработката е ползвала TUNING многократно, затова резултатите върху него са резултати от настройване (приложение А изброява четирите класа данни).

Външни изследвания. Пет невронни репортерни изследвания проверяват преноса (таблица 7). Отделеният набор на всяко от тях съдържа само варианти, при които няма вариант от друго изследване и няма конструкт на Siraj в рамките на 2000 бази, и е един и същ за всички модели. По-ранни модели на проекта вече бяха виждали тези изследвания, затова данните са разкрити. Шесто изследване, Rummel и сътр., е анализ на чувствителността, защото при 83% от вариантите единият алел има по-малко от десет RNA прочита (приложение Б).

5.2 Метод

Признаци. За една редакция моделът образува разликата между редактираната и референтната последователност в два блока признаци (фигура 2). Първият брои 512-те канонични 5-мера, като 5-мер и обратният му комплемент се броят заедно. Вторият има 532 мотивни признака. За всеки мотив на гръбначни от JASPAR 2024 (Rauluseviciute et al. 2024) потенциалът на една последователност е сумата по прозорците ѝ от $\log(1 + s\,r)$, където r е шансът на мотива в прозореца, усреднен по двете вериги, а $s = 0{,}003$ компресира силните сайтове. Потенциалът се мери спрямо прозорец с $r = 1$. Признакът е потенциалът на редактираната последователност минус този на референтната. Различават се само прозорците, които припокриват редакцията, затова оценката зависи от 18-те бази от двете страни на промяната и от нищо по-далечно.

Напасване. Двата блока се напасват заедно, без свободен член, като се минимизира загуба на



Фигура 2. Предсказателят. Редакцията променя два блока признаци. Линеен модел ги превръща в знаков ефект, а панелът взема най-силните редакции, по една от семейство. Studio изпълнява тази контролна точка.

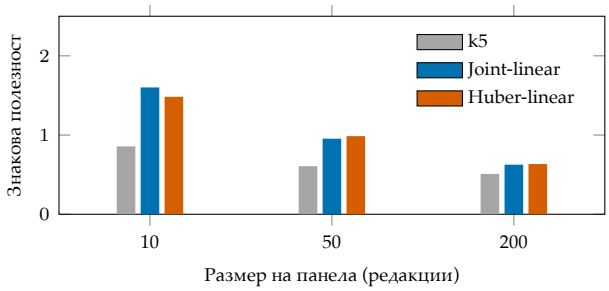
Хюбер (Huber 1964) с наказание 0,01 за блока с 5-мери и 3 за блока с мотиви и с равно тегло на всяко семейство. Прагът на Хюбер се задава веднъж, от медианното абсолютно отклонение на остатъците от напасването с квадратична загуба, и не се променя по време на оптимизацията. Всяко напасване се е сходило за 10 до 13 актуализации. Контролната точка е `epigenesis-siraj-huber-linear-v1`.

Базови модели. *k5* е гребенова регресия само върху блока с 5-мери. *Joint-linear* напасва двата блока със същите наказания и квадратична загуба, така че сравнението му с Huber-линейния модел изолира загубата. *Без ефект* предсказва, че никоя редакция не променя нищо. *S2*, който се ползва в раздел 5.5, е по-ранният модел, обучен върху Siraj, който добавя потенциали на мотиви към k5 (приложение Б).

Панели и полезност. Панел от n редакции се строи, като редакциите се подредят по абсолютен предсказан ефект (равенствата по идентификатор) и се взема първата редакция от всяко още непредставено семейство, докато се съберат n. Знаковата полезност на панела е средният наблюдаван ефект на редакциите му, всеки умножен по знака на предсказания си ефект. При случаен подбор стойността е около нула. Интервалите идват от 2000 преизвадки на цели семейства, а долната граница е 5-ият персентил на печалбата спрямо сравнявания модел.

5.3 Резултати в рамките на анализа

Таблица 4 сравнява модела с базовите му модели във вътрешния дял за настройка. Huber-линейният модел има най-ниската грешка: с 3,02% под k5 и с 5,40% под предсказването на нулев ефект. Joint-linear се различава от него само по загубата, а Huber-линейният го надминава с 0,0030 при положителна долна граница (+0,0002). При панели от 50 и 200 редакции Huber-линейният модел има най-висока полезност (фигура 3). При десет редакции joint-linear е по-горе (1,601 срещу 1,483), защото двата панела се различават в две редакции, и данните не подреждат моделите там.



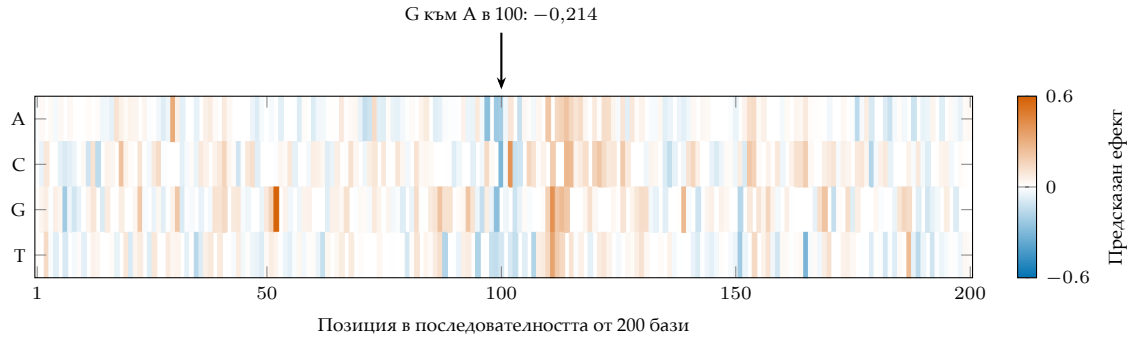
Фигура 3. Знакова полезност на панелите по размер във вътрешния дял за настройка (стойностите са в таблица 4).

Шест от седемте първоначални изисквания са изпълнени. Отвореното е печалбата при десет редакции спрямо k5. Точковата ѝ оценка е положителна (+0,626), а долната ѝ граница е отрицателна (−0,150), така че данните не го разрешават. Разработката е ползвала този дял през цялото

време, затова наричаме подобрението предварително.

5.4 Демонстрация в Studio

Studio изпълнява крайната контролна точка. Демонстрацията ползва два входа, които се доставят с приложението: последователност от 200 бази и таблица от 64 редакции в 11 семейства без измерени стойности, така че всяко число по-долу е предсказание. Скриптът `docs/paper/figure-data.py` възпроизвежда всяка стойност.



Фигура 4. Сканиране в Studio на примерната последователност. Всяка колона е позиция, а всеки ред е базата, в която се променя; празната клетка в колона е референтната база. Оранжевите клетки са предсказани увеличения, а сините са намаления на репортерната активност, наситени при ±0,6. Стрелката сочи първата редакция на примерната таблица.

Сканиране. Поставянето на последователността от 200 бази в раздела Сканиране оценява всичките 600 замени на една база (фигура 4). От 600-те редакции 343 се предсказват да повишават репортерната активност, а 257 да я понижават, и медианният абсолютен ефект е 0,049. Най-голямото повишение е A към G в позиция 52 (+0,581), а най-голямото понижение е G към T в позиция 165 (−0,313). Първата редакция на примерната таблица, G към A в позиция 100, получава −0,214 при Сканиране. Разделът Редакции връща същата стойност за същата редакция като двойка, защото оценката зависи само от базите около промяната.

Редакции. Разделът Редакции приема двойки референтна и редактирана последователност, всяка с по избор семейство, и размер на панела. За панел от пет върху таблицата с 64 редакции петте най-големи абсолютни оценки включват две редакции от едно семейство (локусът chr10:102622941, +0,169 и +0,167). Правилото за подбор запазва първата и преминава към следващото непредставено семейство, така че панелът има пет редакции от пет семейства (таблица 5). Всяка оценка е сума от част за 5-мерите и част за мотивите, които удостоверението записва поотделно.

Удостоверение. Изнасянето на резултата от Редакции записва удостоверение. Зареждането му в раздела Проверка или командата `epigenesis-studio verify` повтаря заявката и преминава и трите проверки, с максимална разлика 0 между записаните и повторно изчислените числа. Таблица 6 показва променени копия: променен резултат пропада на повторното изчисляване дори при преизчислена контролна сума, а преименуван модел пропада на проверката за идентичност. Удостоверението казва на читателя, че резултатът идва от тази контролна точка и тази заявка. То не казва нищо дали предсказанието е вярно.

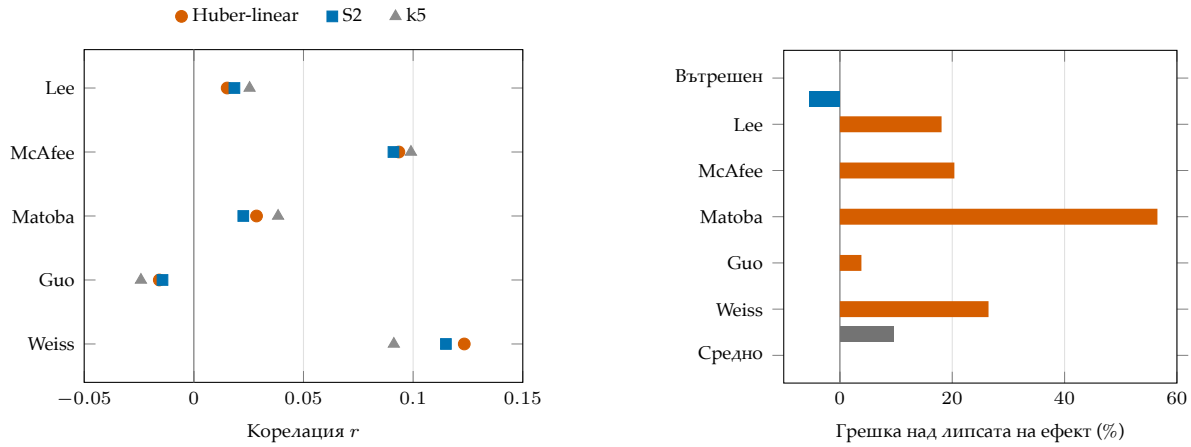
5.5 Пренос към други изследвания

Същата контролна точка беше оценена веднъж, без ново напасване, върху петте невронни репортерни изследвания (таблица 7). Корелациите по изследвания са малки и с различен знак. Средната е 0,0490 срещу 0,0465 за S2 и 0,0460 за k5. Сдвоената печалба спрямо S2 е +0,0024 с интервал от −0,0060 до +0,0109, така че корелациите не разделят моделите.

Грешката е по-строгият тест. Huber-линейният модел има по-ниска средноквадратична грешка

от всеки напасван сравнителен модел. Средната му стойност 0,1044 обаче е с 9,52% над 0,0953 на предсказвател, който казва, че никоя редакция няма ефект, и всяка от петте точки по изследвания и техните интервали е в полза на липсата на ефект (фигура 5). В рамките на анализа същият модел е с 5,40% под този предсказвател. Резултатите в изследванията се различават по определение и мащаб, а сравнението с липса на ефект беше обявено след оценяването, така че това е диагностика, а не повторение на експеримента.

Оценките подреждат редакциите малко по-добре от случайността в тези изследвания, а мащабът им не се пренася от един анализ към друг. Не твърдим пренос към други анализи, типове клетки или ендогенна експресия. Тринайсет фиксирани теста (приложение В) не намериха модел, който надеждно да надмине простите базови модели в различни контексти.



Фигура 5. Вляво: корелация по изследвания (таблица 7). Вдясно: грешка на Huber-linear спрямо предсказването на нулев ефект. Първата лента е вътрешният дял за настройка (под липсата на ефект), следващите пет са изследванията, а последната сравнява двете средни грешки.

5.6 Мотивно-времеви предсказвател на Kreimer за 0–72 ч неврална индукция

Втора контролна точка във версия 1.7, `epigenesis-kreimer-motif-temporal-v1` (`examples/neural-regulation/motif_temporal.py`), моделира времевите смущения в енхансери в седем времеви точки ($[0, 3, 6, 12, 24, 48, 72]$ ч) в набора на Kreimer et al. (2022) за неврална индукция на H1 (GSE188264). По-ранните фиксирани k-мерни модели (`regulation.py`) намалиха квадратичната грешка с 20,97% спрямо нулев ефект, но не надминаха динуклеотиден контрол (приложение Б). `motif_temporal` разширява признаците до същите 512 канонични разлики в 5-мери плюс 532 разлики в потенциалите на мотивите от JASPAR 2024 ($s = 1{,}0$), разлага седемчасовия отговор чрез QR факторизация на ортогонална средна във времето колона и шест колони за времево отклонение и прилага $10\times$ по-силно ридж наказание към времевите отклонения (`word_penalty` $= 0{,}3$, `motif_penalty` $= 3{,}0$, `temporal_multiplier` $= 10{,}0$). Всички хиперпараметри бяха избрани единствено върху разделянето обучение–валидация на ниво семейства преди финалното напасване върху обучение плюс валидация.

Върху 1415 целенасочени смущения в 118 задържани тестови семейства средната по семейства тестова MSE спада до **0,252079** срещу 0,285185 за базовия модел по последователност k5, 0,319358 за динуклеотиди и 0,360870 за предсказване на нулев ефект. Доверителните 95% бутстрап интервали по цели семейства остават положителни спрямо всеки сравняван модел: $[0{,}041258;\ 0{,}188584]$ спрямо нулев ефект, $[0{,}008174;\ 0{,}138345]$ спрямо динуклеотиди и $[0{,}007810;\ 0{,}061363]$ спрямо k5. Върху центрирани по време траектории MSE на времевия контраст се подобрява от 0,032108 на **0,031285** ($[0{,}000220;\ 0{,}001528]$). Двойки последователности с произволна дължина (от 5 до 16 384 бази, включително неравни вмъквания и изтривания) се компилират в модули `brainc` v2, а Studio показва приносите на мотивите от JASPAR за всяка редакция заедно със седемточковата крива. Тъй като оценките на GSE188264 са предобработени с MPRAnalyze преди разделянето и 118-те

тестови семейства са разглеждани при по-ранните k-мерни проучвания, този резултат е ретроспективен и условен (`biological_development_accepted = False`).

5.7 Предназначение

И двата предсказвателя са предназначени за подреждане на редакции в рамките на съответния анализ или за проучване на хипотези — например за съпоставяне на пасивни MPRA предсказания с обръщания на клетъчната съдба в спрегнати ОДУ в раздел 4.4. Нито един от предсказвателите не е валидиран за директно пренасяне между различни анализи или ендогенни клинични ефекти без ново потвърждение.

6 Epigenesis Studio

Studio (`studio/`, команда `epigenesis-studio` или `epigenesis studio`) е локално настолно приложение във версия 0.2.0. Сървърът му слуша само на 127.0.0.1 и отхвърля заявки, чийто Host заглавен ред не е локален. Интерфейсът е на английски и български с превключвател в страничната лента. Приложението има пет раздела (таблица 8).

Симулация и Верига на енхансер изпълняват програмите от раздел 4 на живо; втори симулатор няма. И двата раздела изискват копие на хранилището; без него те са изключени, а останалите работят.

Сканиране и Редакции изпълняват или Huber-линейната контролна точка на Siraj, или мотивновремевия модел на Kreimer за 0–72 ч от раздел 5. Сканиране оценява всяка промяна на една база в прозорец около позицията, което е равно на оценяването на цели последователности (проверено до 10^{-12}), защото линейните оценки зависят само от локалния радиус за k-мери и мотиви (18 бази от двете страни за Siraj и за Kreimer). Редакции оценява пълни двойки (включително индели и MNV) и избира панела по правилото от раздел 5.2.

Удостоверението (`epigenesis-studio-receipt-v1`) съдържа името на модела, хеша на идентичността му, крайната точка, нормализираната заявка, резултата и SHA-256 контролна сума върху каноничния JSON по RFC 8785 на всичко това. Проверка сверява контролната сума, че името, идентичността и крайната точка на модела съвпадат с инсталацията и че повторното изпълнение на записаната заявка възпроизвежда всеки записан резултат с точност 10^{-9} (таблица 6).

Симулация и Верига на енхансер компилират алелите си в запечатани модули за развитие `brainc`; Сканиране и Редакции запечатват канонични JSON удостоверения директно. Всичките 32 теста на Studio минават и обхващат съвпадението между локален прозорец и цяла последователност (Siraj и Kreimer), подбора на панели, скритите бифуркации и спасяванията във Верига на енхансер, трите проверки на удостоверенията, ограниченията и отказите на входа, HTTP защитите, двуезичното EN/BG съответствие на ключовете и съгласуваността с командния ред.

7 Граници и отворени въпроси

Симулация. Всички механистични резултати зависят от заявените допускания от раздел 4.3. Съотношенията на свързване in vitro или Болцмановите суми на състоянията влизат като относителни множители на афинитета без измерено вътреклетъчно калибриране, а броевете ембриони на Peterson et al. (2012) се показват и не се оценяват. Макар версия 1.7 да обобщава дължината на енхансера, избора на PWM матрица (Hallikas GLI2/GLI3, 532 мотива на JASPAR 2024 или потребителски матрици) и произволното свързване на вериги от N гена (`CircuitSpec`), позиционирането на нуклеозоми, кофакторните комплекси, 3D хроматиновите бримки и многоклетъчните фенотипове на организма остават извън модела.

Предсказвател. Вътрешните печалби за Siraj са предварителни, защото разработката е ползвала TUNING, изискването за десет редакции остава отворено, а при тринайсет фиксирани теста за пренос (приложение Б) нито един модел не получи етикет за пренос (правилото за най-близкия

TSS, 0,460, победи всички модели от последователност върху достоверните набори). Резултатите на мотивно-времевия модел на Kreimer за 0–72 ч подобряват ретроспективно базовите модели k5 и динуклеотиди върху GSE188264, но остават условни спрямо публикуваната предобработка с MPRAnalyze и по-рано разглежданите тестови семейства. Затова предсказването между биологични контексти остава отворен проблем.

Оценка. Хешовете на фиксираната процедура са локални; те пазят от грешки вместо от умишлено пренаписване, а тринайсетте теста за пренос не са коригирани за множествено тестване. Няколко външни набора са били разкрити на по-ранни модели или споделят лабораторни линии. Крайната точка на предсказвателя е репортерна активност или експресия, а не клетъчна съдба или морфология.

Следващи стъпки. (а) Сравнение на симулираните скрити бифуркации и епистатичните спасявания чрез втора мутация с измерени ендогенни редакции с CRISPR, при замяна на допуснатите параметри на афинитета с биохимични измервания. (б) Еднократна оценка на запечатания дял RESERVE на Siraj за един предварително избран кандидат. (в) Събиране на нови, неразкрити набори от ендогенни локуси и различни контексти при калибриран мащаб.

8 Заключение

Epigenesis версия 1.7 свързва ДНК последователности под изрични, независимо преизпълнявани тълкувания както с механистични симулации на клетъчна съдба за N гена, така и с интерпретируеми предсказватели от последователност. В единичен 9-базов сайт за GLI замяна премества Nkx2.2 от 0,940 на 0,0085, докато връщането възстановява референтната траектория точно; в пълни енхансери от 171 бази и многофакторни вериги сканирането с Болцманова сума разкрива скрити бифуркации, при които пасивните репортери едва се помръдват, докато спрегнатата обратна връзка обръща клетъчната идентичност, заедно с кандидат-спасявания на втора позиция. Заедно с предсказвателите на Siraj и на Kreimer за 0–72 ч и двуезичните удостоверения в Studio всяко изпълнение остава изчислително проверимо при ясно посочен биологичен обхват и граници на пренос.

9 Наличност и декларации

Код и данни. `https://github.com/dttdrv/epigenesis`. Кодът е под Apache-2.0. Включените данни и компоненти на трети страни запазват лицензите и авторските си бележки: JASPAR 2024 е под CC BY 4.0, бележката за 80K-Analysis е в `examples/neural-predictor/LICENSE.Salomon`, а включеният предсказател с внимание използва Interlace (вж. `NOTICE.md`).

Изпълнение. Python 3.11 или по-нов изпълнява компилатора, обединения команден ред (`python3.11 epigenesis_cli.py check --full`) и основните експерименти само със стандартната библиотека. Studio (`uv tool install --editable studio --with-editable .`) и предсказвателите от последователност изискват NumPy; структурното свързване с CX3D използва Java 21 и `patch`.

Данни за фигурата. `docs/paper/figure-patterning.csv` записва симулацията за 9-базовия GAACACCCA с GLI2 (сигнал $S = 0{,}2$, 20 единици на модела). `docs/paper/figure-data.py` възстановява `figure-scan.csv` и `figure-studies.csv` и отпечатва числата от демонстрацията в раздел 5. Числата в таблица 3 се възпроизвеждат чрез `circuit.py` в `examples/neural-circuit/` (`demo`, `benchmark`, `scan`); числата от раздел 5.6 се възпроизвеждат чрез `tests/verify.py neural-regulation-motif`.

Фиксирани тестове. Плановете, хешовете, скриптовете и резултатите са в `research/frozen-tests/` (приложение B). `python3.11 research/check_freeze.py` преизчислява хешовете. Дялът RESERVE на Siraj остава запечатан. Потвържденията на Salomon и на Kosicki са изразходвани.

Данни без журнална статия. Серии на Gene Expression Omnibus GSE244011, GSE211045, GSE225815, GSE221384, GSE152404 и GSE188264 (Kreimer et al. 2022); хранилището 80K-Analysis (`https://github.com/kircherlab/80K-Analysis`); Interlace (`https://github.com/MisulOrg/Inte`

`rlace`); CX3D 0.03 (`https://tilde.ini.uzh.ch/~amw/seco/cx3d/cx3d-0.03.zip`); GENCODE v39 (Frankish et al. 2021); пътеките UCSC hg38 и phyloP100way.

Отговорност. Авторът отговаря за съдържанието. Всички числа идват от изпълнимите проверки, файловете с резултати, изброени в приложение B, папките на примерите и README на проекта. Конфликт на интереси и финансиране: да се допълнят от автора преди изпращане за публикуване.

Литература

Agarwal V, Inoue F, Schubach M, et al. (2025). Massively parallel characterization of transcriptional regulatory elements. *Nature* 639:411–420. doi:10.1038/s41586-024-08430-9

Ashuach T, Fischer DS, Kreimer A, et al. (2019). MPRAnalyze: statistical framework for massively parallel reporter assays. *Genome Biology* 20:183. doi:10.1186/s13059-019-1787-z

Avsec Ž, Agarwal V, Visentin D, et al. (2021). Effective gene expression prediction from sequence by integrating long-range interactions. *Nature Methods* 18:1196–1203. doi:10.1038/s41592-021-01252-x

Aygün N, Elwell AL, Liang D, et al. (2021). Brain-trait-associated variants impact cell-type-specific gene regulation during neurogenesis. *American Journal of Human Genetics* 108:1647–1668. doi:10.1016/j.ajhg.2021.07.011

Balaskas N, Ribeiro A, Panovska J, et al. (2012). Gene regulatory logic for reading the Sonic Hedgehog signaling gradient in the vertebrate neural tube. *Cell* 148:273–284. doi:10.1016/j.cell.2011.10.047

Beal J, Lu T, Weiss R. (2011). Automatic compilation from high-level biologically-oriented programming language to genetic regulatory networks. *PLoS ONE* 6:e22490. doi:10.1371/journal.pone.0022490

Bergmann FT, Adams R, Moodie S, et al. (2014). COMBINE archive and OMEX format: one file to share all information to reproduce a modeling project. *BMC Bioinformatics* 15:369. doi:10.1186/s12859-014-0369-z

Bilitchenko L, Liu A, Cheung S, et al. (2011). Eugene – a domain specific language for specifying and constraining synthetic biological parts, devices, and systems. *PLoS ONE* 6:e18882. doi:10.1371/journal.pone.0018882

Cai Y, Lux MW, Adam L, Peccoud J. (2009). Modeling structure-function relationships in synthetic DNA sequences using attribute grammars. *PLoS Computational Biology* 5:e1000529. doi:10.1371/journal.pcbi.1000529

Chen KM, Wong AK, Troyanskaya OG, Zhou J. (2022). A sequence-based global map of regulatory activity for deciphering human genetics. *Nature Genetics* 54:940–949. doi:10.1038/s41588-022-01102-2

Cohen M, Page KM, Perez-Carrasco R, Barnes CP, Briscoe J. (2014). A theoretical framework for the regulation of Shh morphogen-controlled gene expression. *Development* 141:3868–3878. doi:10.1242/dev.112573

Deng C, Whalen S, Steyert M, et al. (2024). Massively parallel characterization of regulatory elements in the developing human cortex. *Science* 384:eadh0559. doi:10.1126/science.adh0559

Frankish A, et al. (2021). GENCODE 2021. *Nucleic Acids Research* 49:D916–D923. doi:10.1093/nar/gkaa1087

Fromer M, Roussos P, Sieberts SK, et al. (2016). Gene expression elucidates functional impact of polygenic risk for schizophrenia. *Nature Neuroscience* 19:1442–1453. doi:10.1038/nn.4399

Gneiting T, Raftery AE. (2007). Strictly proper scoring rules, prediction, and estimation. *Journal of the American Statistical Association* 102:359–378. doi:10.1198/016214506000001437

Gong et al. (2020). The requirement of Sox2 for the spinal cord motor neuron development of zebrafish. *Frontiers in Molecular Neuroscience* 13:34. doi:10.3389/fnmol.2020.00034

GTEx Consortium (2020). The GTEx Consortium atlas of genetic regulatory effects across human tissues. *Science* 369:1318–1330. doi:10.1126/science.aaz1776

Guo et al. (2023). Integrative analyses highlight functional regulatory variants associated with neuropsychiatric diseases. *Nature Genetics* 55:1876–1891. doi:10.1038/s41588-023-01533-5

Hallikas O, Palin K, Sinjushina N, et al. (2006). Genome-wide prediction of mammalian enhancers based on analysis of transcription-factor binding affinity. *Cell* 124:47–59. doi:10.1016/j.cell.2005.10.042

Herrera-Delgado E, Briscoe J, Sollich P. (2020). Tractable nonlinear memory functions as a tool to capture and explain dynamical behaviors. *Physical Review Research* 2:043069. doi:10.1103/PhysRevResearch.2.043069

Huber PJ. (1964). Robust estimation of a location parameter. *Annals of Mathematical Statistics* 35:73–101. doi:10.1214/aoms/1177703732

Jaffe AE, Straub RE, Shin JH, et al. (2018). Developmental and genetic regulation of the human cortex transcriptome illuminate schizophrenia pathogenesis. *Nature Neuroscience* 21:1117–1125. doi:10.1038/s41593-018-0197-y

Jerber J, Seaton DD, Cuomo ASE, et al. (2021). Population-scale single-cell RNA-seq profiling across dopaminergic

neuron differentiation. *Nature Genetics* 53:304–312. doi:10.1038/s41588-021-00801-6

Kang HJ, Kawasawa YI, Cheng F, et al. (2011). Spatio-temporal transcriptome of the human brain. *Nature* 478:483–489. doi:10.1038/nature10523

Kelley DR, Snoek J, Rinn JL. (2016). Basset: learning the regulatory code of the accessible genome with deep convolutional neural networks. *Genome Research* 26:990–999. doi:10.1101/gr.200535.115

Kelley DR, Reshef YA, Bileschi M, et al. (2018). Sequential regulatory activity prediction across chromosomes with convolutional neural networks. *Genome Research* 28:739–750. doi:10.1101/gr.227819.117

Kerimov N, Hayhurst JD, Peikova K, et al. (2021). A compendium of uniformly processed human gene expression and splicing quantitative trait loci. *Nature Genetics* 53:1290–1299. doi:10.1038/s41588-021-00924-w

Kircher M, Xiong C, Martin B, et al. (2019). Saturation mutagenesis of twenty disease-associated regulatory elements at single base-pair resolution. *Nature Communications* 10:3583. doi:10.1038/s41467-019-11526-w

Kreimer A, Ashuach T, Inoue F, et al. (2022). Massively parallel reporter perturbation assays uncover temporal regulatory architecture during neural differentiation. *Nature Communications* 13:1504. doi:10.1038/s41467-022-28659-0

Lee S, McAfee JC, Lee J, et al. (2025). Massively parallel reporter assay investigates shared genetic variants of eight psychiatric disorders. *Cell* 188:1409–1424.e21. doi:10.1016/j.cell.2024.12.022

Majoros WH, Kim YS, Barrera A, et al. (2020). Bayesian estimation of genetic regulatory effects in high-throughput reporter assays. *Bioinformatics* 36:331–338. doi:10.1093/bioinformatics/btz545

Matoba N, McAfee JC, Krupa O, et al. (2026). Massively parallel assessment of gene regulatory activity at human cortical-structure-associated variants. *Nature Neuroscience*. doi:10.1038/s41593-026-02454-2

McAfee JC, Lee S, Lee J, et al. (2023). Systematic investigation of allelic regulatory activity of schizophrenia-associated common variants. *Cell Genomics* 3:100404. doi:10.1016/j.xgen.2023.100404

Melnikov A, Murugan A, Zhang X, et al. (2012). Systematic dissection and optimization of inducible enhancers in human cells using a massively parallel reporter assay. *Nature Biotechnology* 30:271–277. doi:10.1038/nbt.2137

Miller JA, Ding SL, Sunkin SM, et al. (2014). Transcriptional landscape of the prenatal human brain. *Nature* 508:199–206. doi:10.1038/nature13185

Myint L, Avramopoulos DG, Goff LA, Hansen KD. (2019). Linear models enable powerful differential activity analysis in massively parallel reporter assays. *BMC Genomics* 20:209. doi:10.1186/s12864-019-5556-x

Ng B, White CC, Klein HU, et al. (2017). An xQTL map integrates the genetic architecture of the human brain's transcriptome and epigenome. *Nature Neuroscience* 20:1418–1426. doi:10.1038/nn.4632

Liu et al. (2025). Predicting the DNA binding specificity of transcription factor mutants using family-level biophysically interpretable machine learning. *Nucleic Acids Research* 53:gkaf831. doi:10.1093/nar/gkaf831

Nielsen AAK, Der BS, Shin J, et al. (2016). Genetic circuit design automation. *Science* 352:aac7341. doi:10.1126/science.aac7341

NIST (2015). *Secure Hash Standard (SHS)*, FIPS 180-4. `https://csrc.nist.gov/pubs/fips/180-4/upd1/final`

Peterson KA, Nishi Y, Ma W, et al. (2012). Neural-specific Sox2 input and differential Gli-binding affinity provide context and positional information in Shh-directed neural patterning. *Genes & Development* 26:2802–2816. doi:10.1101/gad.207142.112

Pollard KS, Hubisz MJ, Rosenbloom KR, Siepel A. (2010). Detection of nonneutral substitution rates on mammalian phylogenies. *Genome Research* 20:110–121. doi:10.1101/gr.097857.109

Ramasamy A, Trabzuni D, Guelfi S, et al. (2014). Genetic variability in the regulation of gene expression in ten regions of the human brain. *Nature Neuroscience* 17:1418–1428. doi:10.1038/nn.3801

Rauluseviciute I, Riudavets-Puig R, Blanc-Mathieu R, et al. (2024). JASPAR 2024: 20th anniversary of the open-access database of transcription factor binding profiles. *Nucleic Acids Research* 52:D174–D182. doi:10.1093/nar/gkad1059

Roadmap Epigenomics Consortium, Kundaje A, Meuleman W, et al. (2015). Integrative analysis of 111 reference human epigenomes. *Nature* 518:317–330. doi:10.1038/nature14248

Rummel CK, Gagliardi M, Ahmad R, et al. (2023). Massively parallel functional dissection of schizophrenia-associated noncoding genetic variants. *Cell* 186:5165–5182.e33. doi:10.1016/j.cell.2023.09.015

Rundgren A, Jordan B, Erdtman S. (2020). *JSON Canonicalization Scheme (JCS)*, RFC 8785. `https://www.rfc-editor.org/rfc/rfc8785`

Salomon K, Deng C, Dash PM, et al. (2026). Massively parallel characterization and predictive modelling of neuronal regulatory variation. *bioRxiv* (preprint, posted 17 July 2026). doi:10.64898/2026.07.16.738760

Schwartzentruber J, Foskolou S, Kilpinen H, et al. (2018). Molecular and functional variation in iPSC-derived

sensory neurons. *Nature Genetics* 50:54–61. doi:10.1038/s41588-017-0005-8

Seitz EE, McCandlish DM, Kinney JB, Koo PK. (2024). Interpreting cis-regulatory mechanisms from genomic deep neural networks using surrogate models. *Nature Machine Intelligence* 6:701–713. doi:10.1038/s42256-024-00851-5

Siraj L, et al. (2026). Functional dissection of complex trait variants at single-nucleotide resolution. *Nature*. doi:10.1038/s41586-026-10121-6

Tareen A, Kooshkbaghi M, Posfai A, et al. (2022). MAVE-NN: learning genotype-phenotype maps from multiplex assays of variant effect. *Genome Biology* 23:98. doi:10.1186/s13059-022-02661-7

Tewhey R, Kotliar D, Park DS, et al. (2016). Direct identification of hundreds of expression-modulating variants using a multiplexed reporter assay. *Cell* 165:1519–1529. doi:10.1016/j.cell.2016.04.027

Traets JJ, van der Burght SN, Rademakers S, et al. (2021). Mechanism of life-long maintenance of neuron identity despite molecular fluctuations. *eLife* 10:e66955. doi:10.7554/eLife.66955

Vaishnav ED, de Boer CG, Molinet J, et al. (2022). The evolution, evolvability and engineering of gene regulatory DNA. *Nature* 603:455–463. doi:10.1038/s41586-022-04506-6

Walker RL, Ramaswami G, Hartl C, et al. (2019). Genetic control of expression and splicing in developing human brain informs disease mechanisms. *Cell* 179:750–771.e22. doi:10.1016/j.cell.2019.09.021

Wang G, Sarkar A, Carbonetto P, Stephens M. (2020). A simple new approach to variable selection in regression, with application to genetic fine mapping. *Journal of the Royal Statistical Society Series B* 82:1273–1300. doi:10.1111/rssb.12388

Weiss CV, Harshman L, Inoue F, et al. (2021). The cis-regulatory effects of modern human-specific variants. *eLife* 10:e63713. doi:10.7554/eLife.63713

Wilson ML, et al. (2016). Genotype Specification Language. *ACS Synthetic Biology* 5:471–478. doi:10.1021/acssynbio.5b00194

Young AMH, Kumasaka N, Calvert F, et al. (2021). A map of transcriptional heterogeneity and regulatory variation in human microglia. *Nature Genetics* 53:861–868. doi:10.1038/s41588-021-00875-2

Zhou J, Troyanskaya OG. (2015). Predicting effects of noncoding variants with deep learning–based sequence model. *Nature Methods* 12:931–934. doi:10.1038/nmeth.3547

Zubler F, Douglas R. (2009). A framework for modeling the growth and development of neurons and networks. *Frontiers in Computational Neuroscience* 3:25. doi:10.3389/neuro.10.025.2009

Zubler F, Hauri A, Pfister S, et al. (2011). An instruction language for self-construction in the context of neural networks. *Frontiers in Computational Neuroscience* 5:57. doi:10.3389/fncom.2011.00057

Zubler F, Hauri A, Pfister S, et al. (2013). Simulating cortical development as a self constructing process: a novel multi-scale approach combining molecular and physical aspects. *PLoS Computational Biology* 9:e1003173. doi:10.1371/journal.pcbi.1003173

A Процедура с предварително фиксиран план

Всеки тест в приложение Б следва една и съща процедура.

1. **План.** Файл с план фиксира въпроса, съвкупностите, моделите, базовите модели, мерките, бутстрапа, критериите за решение и етикета, който би получил успешният тест.
2. **Хеш.** `FREEZE.json` записва SHA-256 хешове на плана, скриптовете и входните данни, преди да бъде прочетен какъвто и да е резултат. Прогнозите идват от скрипт, който никога не вижда отделените резултати, и хешът им се добавя към записа.
3. **Проверка на оценителя.** Скриптът за оценка се изпълнява върху синтетичен положителен случай, при който етикетът трябва да излезе верен, и върху синтетичен нулев случай, при който не бива. Оценител, който не издържи някой от двата, се поправя преди оценката.
4. **Еднократна оценка.** Оценителят проверява хешовете, оценява запечатаните прогнози и записва един резултат. Променен модел изисква нов план и, ако данните са изразходвани, нови данни.
5. **Преценка.** Етикетът се присъжда само ако всички критерии са изпълнени. Например долната граница на кандидата е над нулата, кандидатът надминава най-добрия фиксиран базов модел и надминава модел, обучен върху други данни.

Единица за преизвадка е семейството от последователности, генът или достоверният набор

(credible set). Единиците се вземат повторно като цели копия в 2000 бутстрап извадки. Интервалите са от 5-ия до 95-ия персентил, така че долният им край е едностранна 95% граница. Корелациите са корелации на Пиърсън, претеглени по семейства, като всяко изследване има равно тегло. Качеството на подбора е знакова полезност. Това е наблюдаваният ефект, със знака на предсказаната посока, на промените, които моделът избира (по една на семейство), за панел от 10, 50 или 200. При случаен подбор стойността е около нула. Посоката се оценява като точност, като равенствата се броят за половин.

Данните са в четири класа. *Запечатаните* не са отваряни (дялът RESERVE на Siraj). *Изразходваните* са оценени веднъж и не могат да потвърдят по-късни модели (потвържденията на Salomon и на Kosicki). *Разкритите* са насочвали разработката (дялът TUNING на Siraj, по-рано оценените репортерни изследвания и всеки тестов набор с eQTL след първото му оценяване). Резултатите върху тях носят резерва за адаптивност. *Новите* са непознати за всички модели в теста.

Б Изследователски запис: тестове за пренос от последователността

Тестовете питат дали само последователността предсказва какво прави невиждана промяна в ДНК в нервни клетки. Те са доказателството зад границата на преноса от раздел 5.5.

Б.1 Задача, данни и модели

Задача. При дадена референтна и променена последователност да се предскаже репортерният ефект, алтернативен минус референтен (логаритъм с основа 2 от отношение). За естествени варианти да се предскаже посоката на ефекта върху генната експресия.

Данни за обучение. Основният набор е репортерният скрининг в SK-N-SH на Siraj et al. (2026) (раздел 5.1). Данните от неврони WTC11-NGN2 (Salomon et al. 2026) дават активност и ефекти за един клас модели. Във всяко изследване резултатите се центрират и мащабират до единично стандартно отклонение, претеглено по семейства, преди обединяването.

Данни за оценка. Шест нервни репортерни изследвания с алелни ефекти: Lee et al. (GSE244011; 5916 варианта; Lee et al. 2025), McAfee et al. (GSE211045; 1682; McAfee et al. 2023), Matoba et al. (4013; Matoba et al. 2026), Rummel et al. (GSE225815; 611; Rummel et al. 2023), Guo et al. (GSE221384; 748; Guo et al. 2023) и Weiss et al. (GSE152404; 9247; Weiss et al. 2021). Наборът на Matoba е обучителният дял на проекта. Раздел 5.1 описва отделените набори, а таблица 7 дава размерите им. Семейство е свързан компонент от варианти в рамките на 2000 бази (геномен локус за Matoba).

Модели. *k5* е гребенова (ridge) регресия върху разликата в броя на каноничните 5-мери (512 коефициента). *S1* е k5, обучен върху скрининга на Siraj. *S2* добавя разликата в потенциалите на мотивите от JASPAR 2024 (Rauluseviciute et al. 2024) и служи за еталон. *Huber-linear* напасва същите 512 коефициента за думи и 532 за мотиви със загуба на Хюбер и е крайният модел. *S3* и *H3* добавят квадратичен член за контекста на мотивите. Обучени са съответно върху Siraj и върху другите изследвания. *H2* е k5 плюс мотиви, обучен върху другите изследвания. *Cfit* е напасната смес от модели, обучени върху изследванията, и модели, обучени върху Siraj. Други модели са гребенова регресия върху 611 оценки на Sei (Chen et al. 2022) и конволюционна мрежа, обучена върху обединените ефекти. Има още модел за пренос на активност, научена от измервания на WTC11-NGN2 (вдъхновен от Seitz et al. 2024; Tareen et al. 2022). Последният е модел без обучение, който умножава промяната в заетостта на мотива по експресията на транскрипционния фактор в неокортекса между 8-ата и 13-ата седмица след зачатието (Kang et al. 2011; Miller et al. 2014).

Б.2 По-ранни отрицателни експерименти

Два експеримента извън серията на Siraj завършиха с отрицателен резултат. Първият е фиксиран k-мерен предсказвател за невралната индукция на H1 (`examples/neural-regulation/regulation.py`). Фиксираният му модел намалява средноквадратичната грешка с 20,97% спрямо нулев ефект, но не издържа изискваното сравнение с динуклеотиден модел (раздел 5.6 представя мотивно-

времевото продължение от версия 1.7, което ретроспективно надминава както k5, така и динуклеотидния контрол). Вторият е проверка на модела FamilyCode за свързване на хомеодомени (Liu et al. 2025) върху *Nkx2-2*, която също не издържа.

Б.3 Проверки на измерванията

Прогноза за пропуснати повторения. В пилотно проучване на нервен анализ пропускахме по едно РНК повторение и прогнозирахме алелния му дял от останалите, с модела BIRD (Majoros et al. 2020) или чрез обединяване с аналитично бета-биномно разпределение, и оценихме прогнозите с непрекъснатия ранжиран вероятностен резултат (CRPS; Gneiting and Raftery 2007). При дванайсет пропускания в четири компонента от обучителния набор средният CRPS е 0,0549 за BIRD и 0,0622 за обединяването, тоест с 11,7% по-нисък. Условният 99% симулационен интервал за разликата е от 0,0044 до 0,0098 и обхваща само грешката на Монте Карло за тази подбрана група. Средните на всичките четири компонента се подобряват, а единственото пропускане в полза на обединяването е запазено. BIRD и обединяването се различават и по приори, така че сравнението не отделя вариацията между повторенията като причина. Последващо сравнение с нормализация по ДНК понижава средния CRPS с 15,8% спрямо обединяването, но апостериорна прогноза за нулев ефект постига по-добър резултат.

Прогноза за по-късни отговори. В анализа на невралната индукция на Kreimer et al. (2022) гребеновата регресия върху четири ранни измервания намалява грешката с 24% спрямо пренасянето на 12-часовата стойност, при 351 задържани семейства, и се изравнява с по-прост контрол чрез осредняване. Два предварително обучени модела за прогноза без допълнително обучение не се справят по-добре. Тест с необработени броеве, който отделя семейства и инфектирани култури, дава средноквадратична грешка 0,3213 срещу 0,3221 за липса на промяна (с 0,26% по-добре). И четирите интервала за разликата включват нулата.

Шум от броенето. В GSE225815 при 83% от вариантите единият алел има по-малко от десет РНК прочитания, затова логаритъмът на отношението се определя главно от псевдоброя и от дисбаланса в ДНК броевете. Високото съгласие между половините на повторенията (0,98) идва от общия ДНК брой и нищо не казва за възпроизводима биология: при 124-те добре измерени варианта изходният слой (head), обучен върху Siraj, дава $r = -0{,}09$. Другите три изследвания с броеве имат пренебрежим шум от броенето (медианна поасонова дисперсия под 0,002 $\log_2^2$). Затова махнахме GSE225815 от основната група в по-късните тестове и го запазихме като анализ на чувствителността.

Б.4 Репортерни ефекти

В рамките на един анализ. Раздел 5.3 дава вътрешното сравнение на Huber-linear с k5. Две по-ранни потвърждения върху изразходвани данни, за по-ранни напасвани предсказватели от тази серия, не успяха. Потвърждението на Kosicki (3840 промени в 50 семейства) даде грешка 0,016958 за фиксирания предсказвател срещу 0,016919 за нулев ефект. Полезността му при десет промени беше −0,038 срещу +0,023 при случаен подбор. Потвърждението на Salomon (7372 промени в 2938 семейства) даде грешка 0,028957 срещу 0,028998 за k5 и полезност при десет промени 0,170 срещу 0,153. Всичките седем точкови сравнения бяха в полза на модела, но всеки интервал включваше нулата.

Между изследвания. Таблица 9 изброява тестовете, които прилагат фиксиран модел върху други изследвания. Еталонът S2 е обучен само върху Siraj. Той има $r \approx 0{,}047$ (S1 има 0,047 върху всичките шест изследвания, интервал от 0,026 до 0,069), тоест $r^2 \approx 0{,}002$. S2 е положителен в четири от петте изследвания без GSE225815. След проверката на шума от броенето тези пет изследвания са основната група. Групата от шест се пази като анализ на чувствителността.

Тест 8 е крайният модел (раздел 5.5, който дава и сравнението с прогноза за нулев ефект). Корелациите на S2 по изследвания са от −0,014 (Guo et al.) до 0,115 (Weiss et al.). В проучвателен анализ с подбор по резултата знакът на предсказанието на S2 е верен за 53% до 57% от 10-те процента най-големи ефекти в изследванията на Lee, Matoba и Weiss, срещу 50% общо. Това е само посока

за проверка. Еволюционната консервация (phyloP100way; Pollard et al. 2010) не помага. Корелацията ѝ с абсолютния ефект е средно 0,017, а умножаването на S2 по консервацията понижава средното r от 0,047 на 0,034.

Б.5 Естествени варианти

Посока на ефектите върху експресията. Данните за обучение бяха QTL с фино картиране от мозък на възрастни: мозъчни региони на GTEx, BrainSeq, CommonMind, ROSMAP и Braineac2 в eQTL Catalogue (GTEx Consortium 2020; Jaffe et al. 2018; Fromer et al. 2016; Ng et al. 2017; Ramasamy et al. 2014; Kerimov et al. 2021). Те съдържат 14 617 двойки вариант-ген с апостериорна вероятност за включване (PIP) поне 0,5, с фино картиране чрез SuSiE (Wang et al. 2020). Валидирането задържа цели хромозоми. Тестовете използваха набори от фетален мозък и от клетки, получени от нервни. M4 използва оценки на хроматина от Sei по интервал на разстоянието до началото на транскрипцията (TSS). M5 добавя промяната в GC, локалния k5 и изходния слой на репортерния модел. Базови модели са B1 (алтернативният алел печели GC), B2 (логистична регресия върху k5) и B3 (изходният слой, обучен върху Siraj, без допълнително напасване).

Обединено за четирите набора от клетки с нервен произход при PIP $\geq 0{,}5$ (626 двойки) M5 достига 0,599 (0,566; 0,630) срещу 0,567 за B2. Най-голямата печалба в един набор, при прогениторите, не се повтори при наборите на Jerber и на сетивните неврони. Нито един модел не стои последователно над базовия модел с k-мери. Трите етикета (за посоката във фетален мозък, за потвърждение в диференциращи се неврони и за повторение в клетки с нервен произход) не бяха присъдени.

Кой вариант в достоверния набор е причинният? Подреждане на членовете на достоверните набори с условна логит регресия беше обучено върху 5836 набора от мозък на възрастни (27 875 члена) със задържане на цели хромозоми. Оценихме точността на първото място (top-1) върху 439 набора от фетален неокортекс (Walker et al. 2019) и 420 набора от клетки с нервен произход (таблица 11).

Никой модел не надминава правилото за най-близкия TSS във фетален неокортекс. При наборите от клетки с нервен произход M4 надминава интервалите на разстоянието с +0,045 (+0,005; +0,085). Той не надминава ясно B1 (M5 − B1 = +0,019, интервал от −0,029 до +0,067). Консервацията не носи сигнал: phyloP избира члена с най-висока вероятност от фино картиране не по-добре от случайността (AUC по двойки 0,495 в обучителните набори и 0,503 при Walker). Добавянето на достъпност на хроматина по DNase от Roadmap (Roadmap Epigenomics Consortium 2015) не помага във фетален неокортекс. Двата модела с достъпност достигат 0,417 и 0,420, под M4 (0,435) и под правилото за най-близкия TSS (0,460). Нито един от двата етикета не беше присъден.

Б.6 Обобщение

В тринайсетте теста изходният слой, обучен върху Siraj, носи слаб, устойчив между изследванията сигнал (r около 0,05), към който нищо от опитаното не добавя. Сигнали, които изглеждат по-добре в един набор, не се повтарят в следващия. Простите базови модели (най-близък TSS, броят на k-мери, изходният слой на репортерния модел) са трудни за надминаване при естествени варианти.

В Фиксирани тестове и къде се намират

Всяка папка в `research/frozen-tests/` съдържа плана (`PLAN.md`), хешовете (`FREEZE.json`), `scripts/`, малки файлове с резултати и `RESULTS.md`. Оригиналното дърво е `build/neural-predictor-reviewed-20261005/` и не е под версионен контрол.

№	Тест	Папка
1	Изключване на по едно изследване, три изследвания	`hnp-loso-20261019`
2	Комбиниран предсказвател, шест изследвания	`hnp-loso6-20261019`
3	Гребенова регресия върху Sei	`sei-features-20261019`
4	Квадратичен контекстен слой	`context-loso6-20261019`
5	Модел за пренос на активност	`activity-transfer-loso6-20261019`
6	Обединена конволюционна мрежа	`cnn-loso6-20261019`
7	Свързване на експресирани транскрипционни фактори без обучение	`mechanism-zeroshot-20261019`
8	Пренос на Huber-linear	`huber-transfer-20261020`
9	Посока на eQTL, фетален неокортекс	`eqtl-brain-20261019`
10	Посока на eQTL, Jerber	`eqtl-brain-20261019` (`PLAN_CONFIRM.md`)
11	Посока на eQTL, сетивни неврони и микроглия	`eqtl-brain-20261019` (`PLAN_REP.md`)
12	Подреждане в достоверен набор	`eqtl-causal-20261019` (`PLAN.md`)
13	Подреждане в достоверен набор с достъпност	`eqtl-causal-20261019` (`PLAN2.md`)

Проучвателен, нефиксиран анализ на консервацията и посоката е в `constraint-factor-20261019`.

Таблица 1. Изпълними експерименти.

Експеримент	Какво прави	Резултат и допускане
Оформяне на невралната тръба	Чете 9-базово заместване на енхансер на *Nkx2.2* (Peterson et al. 2012), измерени съотношения на свързване на GLI (Hallikas et al. 2006) и модел с четири гена (Herrera-Delgado et al. 2020; Cohen et al. 2014)	Връщането на заместването възстановява изходното състояние. Контролите за история на сигнала, спасяване и фенокопие и числовото уточняване минават. Съотношението на свързване in vitro се пренася към вътреклетъчния афинитет по допускане.
Неврална верига (neural circuit)	Сканира произволни енхансери чрез симетрична Болцманова физика (GLI2/GLI3, 532 мотива на JASPAR или потребителски PWM) в ОДУ за N гена (`neural-tube`, `mutual-toggle`, `tri-lineage-switch` или `CircuitSpec`), проверява спасяване с втора мутация и по избор се свързва с CX3D	Разкрива 7 скрити бифуркации на `chr15` (33 в 5 локуса) и 74 при `tri-lineage-switch`; точно 9-базово съвпадение ($< 10^{-15}$) и връщане (0,0). Условно спрямо преноса на сумата на състоянията и некалибрираните единици на модела.
Неврална регулация	Репортерен анализ 0–72 ч за неврална индукция на H1 (Kreimer et al. 2022): фиксиран k-мерен базов модел (`regulation.py`) и мотивно-времеви модел (`motif_temporal.py`)	Базовият k-мерен модел не преминава динуклеотидната проверка; `motif_temporal` постига MSE 0,252079 върху задържани семейства срещу 0,285185 (k5) при 118 семейства, условно спрямо публикуваната предобработка.
Кодиращи последствия	Възстановява промени в *Sox2* от геномен FASTA и ги превежда със стандартния генетичен код на NCBI	Делеция на четири бази дава продукт от 97 аминокиселинни остатъка (69 непроменени) и стоп при кодон 98, което съвпада с мутанта при Gong et al. (2020). Не се твърди нищо за количеството на протеина.
Реконструкция на измервания (neural evidence)	Възстановява 109 наблюдения на експресията на *gcy-22* след изчерпване на CHE-1 при *C. elegans* (Traets et al. 2021), всяко проследено до клетка от работната книга и до замислена промяна в ДНК	Средните съотношения ауксин/контрола са 8,70% при пренесено ядро за свързване от 12 бази и 66,33% при по-голям фрагмент. Ограниченията на извадката и противоречивите етикети в източника остават прикрепени към данните.
Регулаторна динамика (neural fate)	Изчислява динамиката на Pax6, Olig2 и Nkx2.2 от изкуствена рецепта с параметри от 512 бази	Възпроизвежда зададено поведение на публикувани модели с обикновени диференциални уравнения. Уравненията задават взаимодействията. Рецептата не ги открива.
Изграждане на нервна мрежа	Израства клетки, неврити и контакти от една основаваща клетка и изкуствена рецепта от 480 бази (15 параметъра) върху CX3D; стимулира клетките и прекъсва контакти	Морфологията и връзките възникват по време на изпълнението и не са кодирани. Рецептата е изкуствена.

Таблица 2. Работен пример при 20 единици на модела: дял на GLI активатора 0,2, профил на GLI2, всички гени започват от нула. Стойностите са концентрации в единици на модела; заетостта е вероятността промоторът на *Nkx2.2* да е активен.

Изпълнение	Pax6	Olig2	Nkx2.2	Irx3	Заетост
Референтна последователност	0,00519	0,0208	0,940	0,000716	0,940
Вариант, редакция вътре в мрежата	0,241	0,967	0,00846	0,00206	0,00846
Вариант, пасивен репортер	0,00519	0,0208	0,940	0,000716	0,928
Връщане на базата	идентично с референтното; най-голяма абсолютна разлика 0				

Таблица 3. Обобщение на сканиранията на пълни енхансери и многофакторни вериги във версия 1.7 (`neural-circuit`, $S = 0{,}20$ за `neural-tube` и $S = 0{,}35$ за `tri-lineage-switch`).

Енхансер / тест	Верига и фактор(и)	Дълж.	Скрити	Варианти	Спасяване (2-ра база)
`chr15:90936956-90937127`	`neural-tube` (GLI2)	171	7	513	Няма (единично ядро)
Пет *локуса* GSE188264 (тест)	`neural-tube` (GLI2)	171	33	2 565	`chr18`, `chr1`
`chr15:90936956-90937127`	`tri-lineage-switch` (`MA0069.1`+`MA0463.3`)	171	74	513	Поддържано в API

Таблица 4. Вътрешен *дял* за настройка, 16 986 редакции в 1759 семейства. Грешката е средноквадратичната грешка, претеглена по семейства (по-ниска е по-добре). Полезността е знаковата полезност на панел от 10, 50 или 200 редакции (по-висока е по-добре). Последният ред е долният край на интервала от 5-ия до 95-ия персентил на печалбата на Huber-linear спрямо k5 при 2000 преизвадки на цели семейства.

Модел	Грешка	Полезност, 10	Полезност, 50	Полезност, 200
Без ефект	0,304075	0	0	0
k5	0,296611	0,857	0,607	0,509
Joint-linear (квадратична загуба)	0,290683	1,601	0,954	0,626
Huber-linear (краен)	0,287667	1,483	0,986	0,634
Печалба спрямо k5, долна граница	+0,0051	−0,150	+0,140	+0,063

Таблица 5. Панел от пет от примерната таблица с 64 редакции. Семейство е етикетът, който таблицата дава на всяка редакция. Ефектът е предсказаният ефект, алтернативен минус референтен, сумата от частта за 5-мерите и частта за мотивите.

№	Редакция	Семейство	Ефект	Част 5-мери	Част мотиви	Посока
1	chr10:101119242 G>A	101119242	−0,2140	−0,1261	−0,0878	понижава
2	chr10:119062236 C>T	118615567	−0,2033	−0,1434	−0,0599	понижава
3	chr10:102798346 T>C	102622941	+0,1687	+0,1407	+0,0280	повишава
4	chr10:105307889 T>C	105307889	−0,1572	−0,1439	−0,0133	понижава
5	chr10:119050998 C>T	119021407	+0,1326	+0,0162	+0,1164	повишава

Таблица 6. Проверка на удостоверението на панела по-горе и на три променени копия. Последната колона дава най-голямата разлика между записаните и повторно изчислените числа.

Удостоверение	Контролна сума	Идентичност на модела	Повторно изчисляване
Изнесено	да	да	да (0)
Първият записан ефект повишен с 0,001	не	да	не (0,001)
Същото, контролната сума преизчислена	да	да	не (0,001)
Модел преименуван, контролната сума преизчислена	да	не	да (0)

Таблица 7. Huber-linear върху отделените редакции на петте невронни репортерни изследвания, оценен веднъж без ново напасване. r е корелацията на Пиърсън, претеглена по семейства. Грешката е средноквадратичната грешка на Huber-linear и на предсказването на нулев ефект, а Излишъкът е първата като процент над втората. Редовете със средни стойности дават на изследванията равно тегло; излишъкът в реда за средното сравнява двете средни грешки. Matoba има 97 семейства. †Изследване за чувствителност, извън средното.

			Корелация r			Грешка		
Изследване	Редакции	Семейства	Huber	S2	k5	Без ефект	Huber	Излишък
Lee	5916	2340	0,0152	0,0185	0,0254	0,0626	0,0739	+18,10%
McAfee	1682	676	0,0935	0,0910	0,0990	0,0277	0,0333	+20,38%
Matoba	4013	97	0,0286	0,0225	0,0384	0,0164	0,0256	+56,53%
Guo	748	571	−0,0157	−0,0143	−0,0241	0,3479	0,3612	+3,83%
Weiss	9247	6930	0,1233	0,1149	0,0912	0,0220	0,0278	+26,46%
Средно от петте			0,0490	0,0465	0,0460	0,0953	0,1044	+9,52%
Rummel†	611	349	0,0375	0,0488	0,0505	0,5420	0,5503	+1,53%

Таблица 8. Разделите на Studio във версия 0.2.0.

Раздел	Вход	Изход
Симулация	Една замяна в деветбазовия сайт, GLI2 или GLI3, протокол на сигнала до 10 фази и 100 единици на модела и по избор начално състояние	Траектории за референтната последователност, варианта и връщането; сравнение между репортер и мрежа; контроли; шестте допускания; CSV; удостоверение
Верига на енхансер	Подбран локус от GSE188264 или FASTA енхансер (от 9 до 500 бази), готова верига (`neural-tube`, `mutual-toggle`, `tri-lineage-switch`), GLI2/GLI3 или кой да е от 532 мотива на JASPAR, целеви ген(и), по избор SNV/MNV/индел	Сканиране за скрити бифуркации ($3L$ варианта), ендогенна срещу репортерна траектория, 21-точков пространствен домен, импулсно освобождаване, спасявания с втора мутация, `brainc` v2/v3 удостоверения, паралелни оценки от Kreimer/Siraj
Сканиране	Един FASTA запис или обикновена последователност от 5 до 1000 бази (само A, C, G, T; няколко записа се отказват); превключвател Siraj или Kreimer 0–72 ч	Топлинна карта на трите замени във всяка позиция; крива 0–72 ч и водещи JASPAR мотиви (Kreimer); подредена таблица; CSV; удостоверение
Редакции	До 5000 двойки референтна и редактирана последователност (CSV или JSON) с по избор семейство за всяка; превключвател Siraj или Kreimer 0–72 ч	Оценки, водещи допринасящи JASPAR мотиви (Kreimer), панел с поискания размер с по една редакция от семейство; CSV; удостоверение
Проверка	Файл с удостоверение	Три проверки: контролна сума, идентичност на модела и крайната точка, повторно изчисляване на всеки записан резултат

Таблица 9. Тестове между изследвания. r е корелация на Пиърсън, претеглена по семейства, с равно тегло на изследванията (от 5-ия до 95-ия персентил). Всеки тест е оценен веднъж, на 19 и 20 октомври 2026 г. Нито един тест не получи етикета си.

№	Кандидат и съвкупност	r на кандидата	r на еталона
1	H2, обучен върху другите две изследвания; дялове McAfee и Matoba	0,015 (−0,024; 0,054)	S1 0,060
2	Смес Cfit; три новооценени изследвания	0,046 (0,009; 0,082)	S2 0,050
3	Гребенова регресия върху Sei; шест изследвания (смес със S2: 0,041)	−0,003 (−0,024; 0,019)	S2 0,047
4	Квадратичен контекстен слой S3; шест изследвания	0,046	S2 0,047
5	Пренос на активност от WTC11-NGN2; шест изследвания	−0,010 (−0,029; 0,011)	S2 0,047
6	Обединена конволюционна мрежа; пет изследвания	0,014 (−0,008; 0,035)	S2 0,047
7	Свързване на експресирани транскрипционни фактори без обучение; пет изследвания	0,0015	S2 0,0465
8	Huber-linear, фиксиран; пет изследвания	0,0490	S2 0,0465

Таблица 10. Точност на посоката върху задържани eQTL с фино картиране; преизвадка по гени, от 5-ия до 95-ия персентил.

Тестов набор	n	M4	M5	M5 спрямо най-добрия базов
Фетален неокортекс (Walker et al. 2019)	792	0,547	0,566	B3: +0,028 (−0,009; +0,065)
Прогенитори (Aygün et al. 2021)	229	0,528	0,646	B2: +0,066 (0,013; 0,117)
Неврони (Aygün et al. 2021)	80	0,575	0,600	широки интервали
Диференциращи се неврони (Jerber et al. 2021)	320	0,534	0,603	B2: +0,003 (−0,037; +0,045)
Сетивни неврони (Schwartzentruber et al. 2018)	519	0,538	0,518	B2 0,499 (PIP ≥ 0,1)
Микроглия (Young et al. 2021)	272	няма	0,570	изходен слой 0,574

Таблица 11. Точност на първото място при подреждане в достоверен набор (от 5-ия до 95-ия персентил).

Метод	Фетален неокортекс	Набори от клетки с нервен произход
Случаен член	0,355	0,328
Най-близък TSS (B1)	**0,460** (0,420; 0,499)	0,402 (0,362; 0,442)
Интервали на разстоянието (B2)	0,433 (0,403; 0,463)	0,381 (0,351; 0,411)
Най-висок phyloP (B3)	0,355 (0,320; 0,392)	0,333 (0,294; 0,373)
Разстояние + Sei (M4)	0,435 (0,396; 0,474)	**0,426** (0,386; 0,464)
Разстояние + Sei + phyloP (M5)	0,419 (0,381; 0,458)	0,421 (0,381; 0,461)